

Лекція 2

Огляд завдань класифікації, регресії, кластеризації

У машинному навчанні існує величезна кількість методів і алгоритмів, однак майже всі практичні задачі зводяться до трьох фундаментальних напрямів:

- класифікації,
- регресії
- кластеризації.

Відмінність між ними *визначається типом цільової змінної та наявністю або відсутністю міток у даних.*

- Якщо потрібно *передбачити* чи є електронний лист спамом, чи ні (категорії.), то маємо справу із задачею класифікації.
- Якщо потрібно *оцінити* числове значення, як-от вартість квартири, то це *приклад регресії*.
- Якщо дані не мають міток і потрібно знайти приховані структури, як-от, сегменти клієнтів за схожими характеристиками, то застосовується кластеризація.

Узагальнене формулювання задачі

У найзагальнішому вигляді задачу машинного навчання можна описати як *пошук функції відображення між простором ознак і простором вихідних змінних*.

- Нехай є множина об'єктів $X = \{x_1, x_2, \dots, x_n\}$, де кожен об'єкт описується вектором ознак $x_i \in \mathbb{R}^d$.
- Цільова змінна y_i може бути неперервною, дискретною або зовсім невідомою.

Узагальнене формулювання задачі



- Ми шукаємо функцію $f : \mathbb{R}^d \rightarrow Y$, яка на основі даних (x_i, y_i) або лише $\{x_i\}$ наближає приховану залежність у даних. Тип простору Y визначає постановку задачі:
 - Якщо Y є скінченним множиною міток класів, маємо класифікацію.
 - Якщо $Y \subseteq \mathbb{R}$ або $\mathbb{R}^k$, маємо регресію.
 - Якщо Y не заданий, а ми хочемо структурувати X на групи, маємо кластеризацію.

Узагальнене формулювання задачі



Таким чином:

- класифікація - це пошук розбиття простору на області, які відповідають класам;
- регресія - це пошук наближення функціональної залежності $y = f(x)$;
- кластеризація - це пошук відношення подібності, що дозволяє групувати об'єкти.

Важливо, що всі ці задачі зводяться до однієї ключової ідеї:

навчання функції f за обмеженою вибіркою даних, яка узагальнює закономірності на нові, невідомі приклади.

Класифікація



Класифікація – це задача, у якій ми маємо скінченний набір класів і на основі вхідних ознак прагнемо визначити, до якого саме класу належить приклад.

Формально, цільова змінна y є дискретною і набуває значень з множини $\{1, 2, \dots, K\}$, де K – кількість класів.

Завдання алгоритму полягає у побудові функції $f : \mathbb{R}^n \rightarrow \{1, \dots, K\}$, яка відображає вектор ознак у конкретний клас.

Класифікація



Наприклад:

- передбачення результату медичного тесту (позитивний чи негативний) є задачею бінарної класифікації з двома можливими виходами
- класифікація фотографій тварин на котів, собак і птахів – це вже багатокласова класифікація.

Класифікація

Сучасні методи часто використовують ймовірнісну інтерпретацію.

Замість прямого вибору класу вони прогнозують розподіл ймовірностей $P(y = k \mid \mathbf{x})$ для кожного можливого класу.

У випадку бінарної класифікації часто використовується логістична регресія. Ймовірність позитивного класу у ній задається функцією

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}},$$

де $\sigma(z)$ – сигмоїдальна функція, яка відображає будь-яке дійсне число у інтервал $(0, 1)$.

Класифікація

А для багатокласової класифікації застосовується узагальнення *softmax*-регресія:

$$P(y = k \mid \mathbf{x}) = \frac{e^{\mathbf{w}_k^\top \mathbf{x}}}{\sum_{j=1}^K e^{\mathbf{w}_j^\top \mathbf{x}}},$$

де кожен клас має власний вектор параметрів $\mathbf{w}_k$.

Метрики для класифікації

Оцінка якості класифікаційних моделей виконується за допомогою різних метрик.

У класифікаційних задачах найпростіша метрика – *Accuracy* (точність класифікації), яка визначається як відношення кількості правильно класифікованих прикладів до загальної кількості прикладів:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

де TP – кількість істинно позитивних випадків, TN – істинно негативних, FP – хибно позитивних, а FN – хибно негативних.

Accuracy

Проте Accuracy працює, якщо дані є незбалансованими. Наприклад, коли позитивних прикладів значно менше за негативні.

У такому випадку часто розглядають дві метрики:

- *Precision* (точність)
- *Recall* (повнота).

Precision

Точність показує, яка частка передбачених позитивних прикладів справді є позитивними:

$$\text{Precision} = \frac{TP}{TP + FP}.$$

Recall

Повнота, навпаки, показує, яку частку реальних позитивних прикладів вдалося знайти:

$$\text{Recall} = \frac{TP}{TP + FN}.$$

Precision vs Recall

Precision та *Recall* часто "конфліктують" між собою:

- висока точність може досягатися шляхом "обережних" передбачень (мало FP , але багато FN)
- висока повнота – шляхом "ризикованих" передбачень (мало FN , але багато FP).

F1-score

Щоб знайти баланс між *Accuracy* та *Recall*, використовують *F1-score*, що є гармонійним середнім:


$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

ROC-крива

Якщо модель прогнозує ймовірності, то для оцінки якості часто будують *ROC*-криву (Receiver Operating Characteristic), яка відображає залежність між часткою істинно позитивних (*TPR*) та хибно позитивних (*FPR*) при зміні порога класифікації.

Площа під *ROC*-кривою (*AUC*) є агрегованою метрикою: чим вона ближча до 1, тим кращою є модель.

ROC-крива



джерело

Регресія

Регресія вирішує задачу прогнозування неперервної числової змінної на основі вхідних ознак.

Формально, маємо функцію $f : \mathbb{R}^n \rightarrow \mathbb{R}$, яка відображає вектор ознак у дійсне число.

Прикладами є *прогноз вартості нерухомості за характеристиками квартири, передбачення кількості проданих товарів або оцінка рівня забруднення повітря.*


Найпростіша форма – це лінійна регресія, де передбачається, що залежність цільової змінної від входних ознак є лінійною.

Математично вона описується як


$$\hat{y} = \mathbf{w}^T \mathbf{x} + b,$$

Регресія може бути як лінійною, так і нелінійною. Сучасні методи, такі як градієнтний бустинг або нейронні мережі, дозволяють будувати надзвичайно складні регресійні залежності, здатні враховувати взаємодії між ознаками та нелінійні ефекти.


Регресія




Simple Regression



Multiple Regression



Polynomial Regression



Logistic Regression

Метрики для регресії

MSE та RMSE

У регресії основною метою є вимірювання відхилення прогнозів від реальних значень. Найбільш поширеною є середньоквадратична помилка (MSE):

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2,$$

яка більше відкидає великі відхилення сильніше через піднесення у квадрат.

Корінь середньоквадратичної помилки ($RMSE$) більше надається до інтерпретації, оскільки вимірюється в тих самих одиницях, що й сама цільова змінна:

$$RMSE = \sqrt{MSE}.$$

Середня абсолютна помилка (MAE) вимірює відхилення у середньому без піднесення у квадрат:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

Вона більш стійка до викидів у даних.

Коефіцієнт детермінації R^2

Ще однією важливою метрикою є коефіцієнт детермінації R^2 , який показує, яка частка дисперсії у даних пояснюється моделлю:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2},$$

де $\bar{y}$ – середнє значення цільової змінної. Значення R^2 , близьке до 1, означає, що модель добре пояснює варіацію даних, а значення, близьке до 0, означає, що модель не краща за просте прогнозування середнього.

Кластеризація

Кластеризація належить до задач навчання без учителя, оскільки у даних відсутні цільові мітки.

Мета полягає у тому, щоб розбити множину об'єктів на групи, або кластери, так, щоб об'єкти

- всередині одного кластера були максимально подібні між собою
- а між різними кластерами – максимально відмінні.

Формально, для множини прикладів $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ необхідно знайти розбиття на K груп, що мінімізує деяку функцію невідповідності. Наприклад, у методі k -середніх цільова функція має вигляд:

$$\sum_{i=1}^N \sum_{k=1}^K r_{ik} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2,$$

де r_{ik} дорівнює 1, якщо об'єкт $\mathbf{x}_i$ належить кластеру k , і 0 інакше, а $\boldsymbol{\mu}_k$ – центр k -го кластера. Таким чином, алгоритм намагається зменшити суму квадратів відстаней усіх об'єктів до найближчих центрів кластерів.

Кластеризація має численні практичні застосування:

- у маркетингу вона використовується для сегментації клієнтів за схожими характеристиками
- у біоінформатиці – для групування генів за функціональною подібністю
- в урбаністичних дослідженнях – для виявлення районів з подібними соціально-економічними характеристиками.

Метрики для кластеризації

Метрики для кластеризації



Оскільки у задачах кластеризації зазвичай відсутні «правильні» мітки, якість оцінюють за допомогою внутрішніх показників.

Коефіцієнт силуету

Одним з найбільш популярних є коефіцієнт силуету, який для об'єкта i визначається як

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

де $a(i)$ – середня відстань від об'єкта i до інших об'єктів у його кластері, а $b(i)$ – мінімальна середня відстань від об'єкта i до об'єктів іншого кластера.

Коефіцієнт силуету


Значення силуету варіюються $s(i) \in [1, 0]$.

Чим ближче значення до 1, тим краще об'єкт узгоджується з кластером і більше відокремлений від інших.

- $S(i) = 1$. Об'єкт повністю належить до свого кластеру, і відстань до інших кластерів значно більша.
- $S(i) = 0$. Об'єкт знаходиться на межі між двома кластерами, і неможливо чітко визначити, до якого з них він належить.
- $S(i) = -1$. Об'єкт належить до неправильного кластера, тобто його відстань до найближчого кластеру менша, ніж відстань до власного кластеру.



Коефіцієнт силуету

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 5$



Коефіцієнт силуету

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 4$



Індекс Девіса–Болдіна

Ще одним показником є індекс Девіса–Болдіна (DBI):

$$DBI = \frac{1}{K} \sum_{i=1}^K \max_{j \neq i} \frac{\sigma_i + \sigma_j}{d(c_i, c_j)},$$

де σ_i – середня відстань від точок у кластері i до його центру c_i , а $d(c_i, c_j)$ – відстань між центрами кластерів.

Чим менший DBI, тим кращим є розділення кластерів.

Внутрішні та зовнішні метрики



Коли ми виконуємо кластеризацію, то, як правило, у нас немає еталонних класів. У такому випадку якість кластерів оцінюють за допомогою внутрішніх метрик (силует, індекс Девіса–Болдіна тощо), які враховують лише структуру даних.

Проте в окремих завданнях може бути доступна "золота розмітка" (gold standard labels) – наприклад, якщо ми кластеризуємо тексти за темами, а нам відомо, яка стаття належить до якої рубрики. У такому випадку ми можемо оцінити, наскільки отримані кластери відповідають відомим класам. Метрики, що використовують таку інформацію, називають зовнішніми.

Rand Index

Нехай у нас є множина N об'єктів, які ми поділили на кластери. Також відома справжня класифікація. Ми можемо розглянути всі можливі пари об'єктів і подивитися, чи вони віднесені однаково у двох розбиттях:

- a – кількість пар, які належать до одного кластера і в класифікації, і у прогнозованій кластеризації.
- b – кількість пар, які належать до різних кластерів і в класифікації, і у прогнозованій кластеризації.
- c – кількість пар, які належать до одного кластера у справжній класифікації, але в різні у кластеризації.
- d – кількість пар, які належать до одного кластера у кластеризації, але в різні у справжній класифікації.

Rand Index

Тоді $RandIndex(RI)$ визначається як частка "правильних" рішень:

$$RI = \frac{a + b}{a + b + c + d}.$$

RI має значення від 0 до 1, де 1 означає повну відповідність кластеризації еталонним класам.

Проблема Rand Index



Недоліком Rand Index є те, що його значення може бути високим випадково, особливо якщо кластерів багато або їхня структура не збалансована. Наприклад, якщо всі об'єкти помістити в один кластер, то RI може дати не таке вже й низьке значення.

Adjusted Rand Index (ARI)

Щоб уникнути проблем з Rand Index, використовують Adjusted Rand Index, який "віднімає" від Rand Index очікуване значення для випадкового групування і нормалізує результат.

Формула має вигляд:

$$ARI = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]}.$$

ARI змінюється від -1 до 1 :

- $ARI = 1$ – повна відповідність кластерів істинним класам;
- $ARI \approx 0$ – результат не кращий за випадкове розбиття;
- $ARI < 0$ – кластеризація навіть гірша, ніж випадкова.

Приклад ARI



Уявімо, що ми кластеризуємо зображення рукописних цифр (MNIST) без міток.

Для цього ми порівнюємо кластери з реальними мітками цифр (0–9). Якщо кожен кластер приблизно відповідає одній цифрі, *ARI* буде близьким до 1. Якщо ж модель перемішала цифри, показник наблизиться до 0.

Таким чином, ARI дозволяє оцінити, наскільки отримані кластери відповідають очікуваним класам, і при цьому враховує ефект випадковості.

Приклади завдань машинного навчання

Прикладні задачі



Фактично кожне прикладне завдання у бізнесі, фінансах, медицині чи науці можна звести до оптимізаційної задачі: знайти параметри моделі, які мінімізують або максимізують певний функціонал.

Далі наведено кілька узагальнених формулювань для задач класифікації, регресії та кластеризації у різних сферах.

- Коли ми передбачаємо, чи здійснить клієнт покупку, то маємо задачу класифікації. Нехай x_i – вектор характеристик користувача (вік, частота відвідувань сайту, попередні покупки), а $y_i \in \{0, 1\}$ – мітка класу («не купив», «купив»). Модель $f(x; \theta)$ з параметрами θ прогнозує ймовірність покупки. Задача формулюється як мінімізація логістичної втрати:

$$L(\theta) = - \sum_{i=1}^N [y_i \log f(x_i; \theta) + (1 - y_i) \log(1 - f(x_i; \theta))].$$

Електронна комерція

- Коли ж потрібно спрогнозувати суму витрат клієнта, цільова змінна стає неперервною: $y_i \in \mathbb{R}^+$. Це вже регресія, і модель оцінюється через середньоквадратичну помилку:

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i; \theta))^2.$$

- Сегментація клієнтів, формулюється як задача знаходження кластерів $\{C_1, \dots, C_K\}$, що мінімізують відстань до центрів:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2,$$

де μ_k – центр k -го кластера.

- Задача оцінки кредитоспроможності клієнта є класифікаційною.
Для кожного клієнта маємо набір характеристик x_i і бінарну змінну $y_i \in \{0, 1\}$, що відображає факт дефолту чи відсутність дефолту. Функціонал аналогічний логістичній регресії або іншому класифікаційному методу.

- Прогноз ціни активу на наступний день – це задача регресії, де модель $f(x; \theta)$ будує оцінку майбутньої ціни на основі попередніх значень. Оптимізаційна задача:

$$L(\theta) = \sum_{i=1}^N (y_{i+1} - f(x_i; \theta))^2,$$

де y_{i+1} – реальна ціна у момент $i + 1$.

- Групування інвесторів за схожими портфелями – це кластеризація. Мета – знайти структуру у множині векторів $x_i \in \mathbb{R}^n$, що відображають розподіл капіталу по активах. Використовується, наприклад, метод k -середніх або ієрархічна кластеризація.

- Діагностика захворювання за результатами аналізів є класифікацією. Для кожного пацієнта маємо ознаки x_i (аналізи, симптоми) та бінарну або мультикласову мітку y_i . Оптимізаційна задача формулюється як мінімізація крос-ентропійної втрати.
- Прогноз тривалості госпіталізації – це регресія, де вихідна змінна y_i є неперервною (кількість днів). Функціонал втрат може бути MAE або MSE, залежно від вимог до точності та стійкості до аномалій.
- Кластеризація пацієнтів за симптомами або реакцією на лікування формулюється як знаходження груп C_k , у яких схожість усередині максимальна. Це дозволяє виявити патерни та робити персоналізовані рекомендації.

- Прогноз часу прибуття транспорту – регресійна задача, де функція $f(x_i; \theta)$ прогнозує час на основі таких ознак, як відстань, завантаженість доріг чи погода.
- Виявлення нетипових поїздок (наприклад, шахрайських викликів таксі) можна звести до класифікації, де мітка y_i позначає «нормальна» чи «аномальна» поїздка.
- Кластеризація районів за транспортними потоками – це задача без учителя, яка формально записується як мінімізація дисперсії усередині кластерів транспортних характеристик.

- У фізиці віднесення сигналів до різних частинок – це класифікація з багатьма класами. Оптимізаційна задача – мінімізувати втрату крос-ентропії у багатокласовому випадку.
- Прогноз фізичних властивостей сполук – це регресія, де функція $f(x; \theta)$ відображає молекулярні дескриптори у реальні значення, наприклад, температуру кипіння.
- Групування генів у біоінформатиці – це кластеризація, що формулюється як задача знаходження груп із мінімальною внутрішньою дисперсією або максимальною подібністю за певною метрикою.

Усі ці приклади демонструють, що незалежно від сфери застосування, будь-яке завдання машинного навчання зводиться до формальної постановки оптимізаційної задачі.

Ми або мінімізуємо функцію втрат у класифікації та регресії, або шукаємо оптимальне групування у кластеризації.

Таке єдине бачення дозволяє ефективно переносити методи з однієї сфери в іншу, роблячи машинне навчання універсальним інструментом аналізу даних.

Проблеми задач машинного навчання

Якість та обсяг даних



Будь-яка модель «настільки хороша, наскільки хороші дані». Пропуски, аномалії, шум або мала кількість прикладів можуть суттєво знизити якість. Наприклад, у задачі класифікації рідкісних хвороб (1% позитивних прикладів) модель може легко «навчитись» завжди передбачати «здоровий» і досягати 99% точності, але бути повністю марною.

Дисбаланс класів і нерівномірність даних



У класифікації та регресії нерівномірне представлення різних підгруп призводить до зміщення моделі.

У кластеризації — деякі групи можуть бути надто великі або надто розмиті.

Вибір ознак і масштабування



Неправильна або неповна репрезентація даних робить задачу нерозв'язною для моделі. У кластеризації масштаб ознак безпосередньо впливає на відстані й, відповідно, на структуру кластерів.

Проблема перенавчання (overfitting) і недонавчання (underfitting)



Занадто складні моделі можуть «запам'ятати» тренувальні дані й погано узагальнювати; занадто прості — не вловити залежності. Це класичний компроміс *bias–variance trade-off*.

Інтерпретованість



Багато сучасних моделей (наприклад, ансамблі дерев або нейромережі) є «чорними скриньками». Для реальних застосувань (медицина, фінанси) критично важливо пояснювати, чому модель зробила певне передбачення.

Обчислювальні ресурси



Великі дані й складні моделі вимагають значних ресурсів. Обчислювальна вартість може бути обмежуючим фактором навіть у академічних умовах.

Залежність від постановки і метрик



Неправильний вибір метрики чи постановки задачі веде до некоректних результатів. Наприклад, мінімізація MSE у задачі з великими викидами часто призводить до поганих прогнозів, і доцільніше використовувати MAE.