

Лекція 9

SVM, SVR, Байєсівські класифікатори.

Вступ

Розглянуті далі методи машинного навчання залишаються серед найефективніших у задачах з обмеженою кількістю даних, високою розмірністю або потребою у строгій математичній інтерпретації.

- **Методи опорних векторів (Support Vector Machines, SVM):** строгі геометричні алгоритми, що максимізують margin розділення між класами.
- **Регресію опорних векторів (SVR):** варіант SVM для прогнозування числових значень.
- **Байєсівські класифікатори:** сімейство моделей, заснованих на теорії ймовірностей і формулі Байєса.

Support Vector Machine (SVM)

Нехай, наявний набір двовимірних точок двох класів.

- Ми хочемо провести лінію, яка їх розділить. Але таких ліній може бути нескінченно багато.
- Питання полягає в тому яку з них вибрати вибрати?

SVM дозволяє обрати лінію (гіперплощину), що має найбільшу відстань до найближчих точок обох класів. Саме ця відстань називається *margin*.

Геометрична інтерпретація margin

Якщо гіперплощина визначається рівнянням:

$$w^T x + b = 0,$$

то відстань від точки до поверхні:

$$\frac{|w^T x + b|}{|w|}.$$

SVM дозволяє максимізувати:

$$\text{Margin} = \frac{2}{|w|}.$$


Відповідно, чим більший margin тим стійкіша модель.

Геометрична інтерпретація margin

Це означає:

- модель менш чутлива до шуму у даних;
- невеликі зміни у навчальній вибірці не змінюють рішення;
- рішення узагальнюється краще.

Таким чином, SVM — це алгоритм, який адаптується до прикладів класів "на межі".



Постановка задачі

Задача полягає в пошуку таких w, b , щоб усі точки були правильно класифіковані:

$$y_i(w^T x_i + b) \geq 1.$$

Тоді оптимізаційна задача:

$$\min_w \frac{1}{2} |w|^2.$$

Це називається квадратичною оптимізацією.

Робота з реальними даними

Оскільки реальні дані майже ніколи не є безпомилковими, то часто вводять так звані пом'якшення (*slack variables*):

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

І нова задача тоді має такий вигляд:

$$\min_{w, \xi} \frac{1}{2} |w|^2 + C \sum_{i=1}^n \xi_i,$$

- велике C визначає високий штраф за помилки високе, а модель намагається класифікувати все точно, що веде до меншого margin, що несе ризик перенавчання;
- мале C допускає більше помилок, що дає більший margin, і загалом краще узагальнення.

Опорні вектори

Опорні вектори — це точки, які:

- лежать на межі або прилягають до неї,
- визначають положення розділювальної поверхні,
- мають $\xi_i > 0$ або $y_i(w^T x_i + b) = 1$.

Загалом якщо видалити не опорні вектори, рішення SVM не зміниться, що вказує на унікальна властивість, якщо полягає в тому, що *модель залежить від малих, але "критичних" прикладів*.

Якість роботи SVM

SVM використовує *геометричні та оптимізаційні принципи*, які вбудовано захищають модель від перенавчання.

1. **Максимальний margin** сам по собі є регуляризацією.
2. **Опорні вектори** допускають, що лише кілька точок контролюють рішення.
3. **Квадратична оптимізація** забезпечує єдиний глобальний мінімум.
4. **Вибір ядра** дозволяє створити складні нелінійні межі класифікації без збільшення розмірності.

Двоїста форма SVM

Переходимо до оптимізації за коефіцієнтами α_i :

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (x_i^\top x_j)$$

з урахуванням обмежень:

$$0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0.$$

Тут, α_i є множниками Лагранжа, C це параметр регуляризації, який контролює компроміс між максимізацією margin та мінімізацією помилки класифікації, а $x_i^\top x_j$ - лінійне ядро. Яке можна позначити так:

$$x_i^\top x_j \longrightarrow K(x_i, x_j).$$

Ядрові методи SVM

Розглянемо задачу, де класи формують кільця:

- внутрішнє коло — клас 1,
- зовнішнє — клас 0.

У двовимірному просторі вони не є лінійно роздільними.

Але якщо додати ознаку:

$$z = x_1^2 + x_2^2,$$

то дані стануть лінійно віддільними в тримірному просторі.

Проблема полягає в тому, що неможливо передбачити, який саме простір потрібен.

Саме ядра дозволяють SVM працювати так, ніби трансформація вже відбулася.

RBF-ядро

$$K(x_i, x_j) = \exp(-\gamma|x_i - x_j|^2)$$


- якщо дві точки близькі, то ядро ≈ 1 ;
- якщо далекі $\rightarrow$ ядро ≈ 0 .

γ регулює радіус впливу, де

- мале значення параметра γ означає гладку межу розділення, а
- велике γ - складну межу з можливим перенавчання.

Наприклад, у задачах класифікації рукописних цифр, розпізнаванні аномалій, де точки одного класу утворюють кілька локальних кластерів.

У таких ситуаціях RBF автоматично створює нескінченновимірне відображення, що дозволяє моделі будувати гнучкі, вигнуті межі навколо кожних локальних груп, ефективно обгортаючи дані незалежно від їх форми.



Поліноміальне ядро

$$K(x_i, x_j) = (x_i^T x_j + c)^d.$$

Додає взаємодії ознак $x_1 x_2, x_1^2, x_2^3, \dots$, що корисно, якщо ознаки мають природні поліноміальні залежності.

Наприклад, у фізичних задачах траєкторія польоту м'яча залежить від v^2 і $\sin 2\theta$, економіці ефект масштабу, де прибуток зростає як $X + X^2$

У таких випадках SVM з поліноміальним ядром автоматично додає комбінації ознак $x_1^2, x_1 x_2, x_2^2, \dots$, створюючи межу рішення, яке відповідає реальній нелінійній структурі даних.

Приклади для SVM

Класифікація рукописних цифр (MNIST)

- Вихідні ознаки — 784 пікселі.
- Дані розріджені, нелінійні.
- SVM з RBF ядром відомо одна з найточніших класичних моделей.

Визначення шархайства

- Дисбаланс класів.
- SVM із "м'яким" margin + stratified sampling.
- Гранична площа добре відокремлює аномалії.

Support Vector Regression (SVR)



SVR (Support Vector Regression) — це варіант SVM, призначений для розв'язання задач регресії, тобто для прогнозування неперервних значень.

Ідея ε -трубки

У класичній регресії штрафуються всі помилки. У SVR натомість:

- помилки *менші* за ε не вважаються помилками,
- лише точки "поза трубкою" впливають на модель.

Точки всередині трубки — не опорні вектори.



Формулювання задачі SVR

Нехай ми маємо

$$\min_{w,b,\xi,\xi^*} \frac{1}{2} \|w\|^2 + C \sum (\xi_i + \xi_i^*)$$

з обмеженнями:

$$\begin{aligned} y_i - w^T x_i - b &\leq \varepsilon + \xi_i, \\ w^T x_i + b - y_i &\leq \varepsilon + \xi_i^*, \\ \xi_i, \xi_i^* &\geq 0. \end{aligned}$$

- Для великих ε модель ігнорує дрібні коливання, тому ми маємо гладкий тренд.
- Для великих C ми маємо штраф за помилки поза трубкою модель намагається точно проходити через точки.

Двоїста форма SVR

Вводимо множники Лагранжа: $\alpha_i, \alpha_i^* \geq 0$ для обмежень ξ_i, ξ_i^* .

Двоїста задача виглядає так:

$$\begin{aligned} \max_{\alpha_i, \alpha_i^*} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*)(x_i^\top x_j) \\ & - \varepsilon \sum_{i=1}^n (\alpha_i + \alpha_i^*) + \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*) \\ & \sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0, \\ & 0 \leq \alpha_i, \alpha_i^* \leq C. \end{aligned}$$

Двоїста форма SVR

Після знаходження оптимальних α_i, α_i^* , функція прогнозується як:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) (x_i^\top x) + b.$$

Для нелінійної регресії, замість $x_i^\top x_j$ підставляємо ядро $K(x_i, x_j)$:

$$x_i^\top x_j \longrightarrow K(x_i, x_j)$$

Наприклад, для RBF-ядра:

$$K(x_i, x_j) = \exp(-\gamma |x_i - x_j|^2)$$

Тепер прогноз виглядає так:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b$$

Баєсівські класифікатори

Формула Байєса

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)},$$

- $P(y)$ — апіорна ймовірність класу, тобто наскільки часто клас y зустрічається в даних до того, як ми побачили ознаки x .
- $P(x|y)$ — правдоподібність, ймовірність спостереження ознак x , якщо клас y відомий.
- $P(y|x)$ — апостеріорна ймовірність, ймовірність класу y після того, як ми побачили ознаки x .
- $P(x)$ - нормалізуюча константа, ймовірність спостереження ознак x незалежно від класу.

Наївний Баєс (Naive Bayes)

Мета класифікації: обрати клас, що максимізує апостеріорну ймовірність:

$$\hat{y} = \arg \max_y P(y|x).$$

Ми починаємо з наших очікувань щодо ймовірності класів $P(y)$ і коригуємо їх на основі того, що спостерігали $P(x|y)$.

Основне припущення полягає в тому, що ознаки незалежні всередині одного класу.

$$P(x|y) = \prod_{i=1}^d P(x_i|y).$$

Це радикально спрощує модель, але працює напрочуд добре.

Наївний Баєс

Переваги

- Швидка тренування та прогнозування.
- Працює добре навіть якщо ознаки насправді *частково залежні*.
- Потрібно дуже мало даних для оцінки параметрів.

Недоліки

- Якщо ознаки сильно корельовані, точність може знижуватися.
- Для безперервних ознак потрібно робити додаткові припущення (наприклад, Gaussian Naive Bayes).

Вибір моделі для прогнозу

Для кожного класу y обчислюємо апостеріорну ймовірність:

$$P(y|x) \propto P(y) \prod_{i=1}^d P(x_i|y)$$

і обираємо клас з максимальною ймовірністю:

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^d P(x_i|y).$$

Знак пропорційності $\propto$ використовується, бо $P(x)$ однакове для всіх класів і не впливає на $\arg \max$.

Приклад

Уявимо, що ми класифікуємо пошту як *спам/не спам*:

- x_i — наявність певного слова в листі.
- $P(x_i | \text{с п а м})$ — ймовірність, що слово з'являється у спамі.
- $P(\text{с п а м})$ — частка спаму серед всіх листів.

Наївний Байєс поєднує ці ймовірності і дає прогноз:

«спам», якщо апостеріорна ймовірність для спаму більше, ніж для не спаму.

Гаусівський НБ (Gaussian NB)

Використовується для *безперервних ознак* (дійсні числа).

Основне припущення полягає в тому, що значення ознаки для кожного класу розподілені нормально (гаусовий розподіл).

Для ознаки x_i класу y ймовірність:

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_{y,i}^2}} \exp\left(-\frac{(x_i - \mu_{y,i})^2}{2\sigma_{y,i}^2}\right),$$

де $\mu_{y,i}$ та $\sigma_{y,i}^2$ оцінюються з навчальних даних.

Як приклад можна навести прогнозування ризику захворювань за віком, тиском, рівнем холестерину, кожна ознака — числова, і їх розподіл наближено нормальний.

Мультиноміальний NB (Multinomial NB)

Використовується для *дискретних, частотних даних*, як-от кількість слів у тексті і, відповідно, часто застосовується у класифікації текстів.

Для документа $x = (x_1, x_2, \dots, x_d)$ (кількість появ слів):

$$P(x|y) = \frac{(\sum_i x_i)!}{\prod_i x_i!} \prod_{i=1}^d P(x_i|y)^{x_i}.$$

$P(x_i|y)$ — ймовірність слова i у класі y . Тут оцінюється як частка цього слова в документах класу y .

Знову розглянемо фільтрування спаму. Враховуємо, скільки разів слова «виграш», «безкоштовно» зустрічаються в листі. Також прикладом може бути класифікація новин за темами.

Бернуллі НБ (Bernoulli NB)

Використовується для *бінарних ознак* (0/1, слово є/немає). Враховує тільки наявність/відсутність ознаки, а не кількість.

Нехай $x = (x_1, x_2, \dots, x_d)$, тоді апостеріорна ймовірність:

$$P(x|y) = \prod_{i=1}^d P(x_i|y)^{x_i} (1 - P(x_i|y))^{1-x_i}.$$

Наприклад при прогнозуванні наявності певного захворювання $y \in \{\text{хворий}, \text{здоровий}\}$ за результатами простих аналізів маємо бінарні ознаки, які вказуватимуть на наявність чи відсутність симптому.

Можель оцінює ймовірність появи кожного симптому для класу «хворий» та «здоровий». Потім обчислюється апостеріорну ймовірність класу, а клас з більшою ймовірністю обирається як прогноз.