

Лекція 12

Пайплайни машинного навчання, автоматизація підготовки даних

Місце пайплайнів у ML-проєкті

Задачі машинного навчання майже ніколи не зводяться лише до вибору алгоритму та його тренування. Реальний ML-проєкт складається з послідовності взаємопов'язаних етапів: збору даних, очищення, трансформації, інженерії ознак, вибору моделі, навчання, валідації, оцінювання та подальшого використання у продакшені. Якщо ці етапи реалізовані некоректно виникають серйозні ризики: витік ознак, неконсистентність експериментів, неможливість відтворення результатів та помилки при масштабуванні.

Пайплайн машинного навчання — це формалізований спосіб представлення всього процесу навчання таким чином, що кожен крок чітко визначений, параметризований і може бути повторений. Автоматизація підготовки даних у межах пайплайну є ключовою умовою коректності ML-моделі.

Формальна модель ML-пайплайну

З математичної точки зору пайплайн можна розглядати як композицію функцій.

Нехай початкові дані позначено як $X^{(0)}$, а кожен етап підготовки є відображенням:

$$X^{(k+1)} = T_k(X^{(k)}),$$

де T_k — оператор трансформації (очищення, масштабування, кодування, відбору ознак тощо). Після m послідовних перетворень отримуємо:

$$X^{(m)} = (T_{m-1} \circ T_{m-2} \circ \dots \circ T_0)(X^{(0)}).$$

Далі модель машинного навчання f_θ навчається на результаті:

$$\hat{y} = f_\theta(X^{(m)}).$$

Таким чином, повний пайплайн можна подати як єдину функцію:

$$\mathcal{P}(X) = f_\theta(T_{m-1}(\dots T_0(X))).$$

Важливість автоматизації підготовки даних

Підготовка даних майже завжди містить параметри, що обчислюються зі статистик вибірки: середні значення, стандартні відхилення, медіани, квантилі, словники кодування категорій. Формально, такі параметри є оцінками:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2.$$

Якщо ці оцінки обчислюються з використанням усієї вибірки, включно з тестовою, виникає витік ознак.

Пайплайн повинен забезпечувати вимогу, що усі параметри трансформацій оцінюються лише на training-даних і лише потім застосовуються до validation та test. Автоматизація гарантує, що одна і та сама логіка підготовки використовується на всіх етапах — від експериментів до робочого середовища.

Типові компоненти пайплайну підготовки даних

Узагальнений пайплайн підготовки даних зазвичай включає кілька логічних блоків. Спочатку відбувається очищення, де реалізуються операції роботи з пропусками та аномаліями. Ці операції можна формалізувати як відображення:

$$x'_i = \begin{cases} g(x_i), & \text{якщо } x_i \text{ допустиме,} \\ h(x_j), & \text{якщо } x_i \text{ пропущене або аномальне.} \end{cases}$$

Далі застосовується масштабування або нормалізація, які перетворюють простір ознак, але не змінюють відносний порядок спостережень. Наприклад, стандартизація:

$$x_i^{(scaled)} = \frac{x_i - \hat{\mu}}{\hat{\sigma}}.$$

Типові компоненти пайплайну підготовки даних

Наступним кроком часто є кодування категоріальних змінних, яке перетворює дискретні значення у векторний простір. One-Hot Encoding фактично реалізує відображення:

$$c \in 1, \dots, K \longrightarrow e_c \in \mathbb{R}^K,$$

де e_c — одиничний вектор.

Усі ці кроки повинні бути частиною єдиного автоматизованого ланцюга.

Пайплайни та крос-валідація

Важливу роль пайплайни відіграють у поєднанні з k-fold крос-валідацією. Нехай вибірка розбита на k фолдів $D_1, \dots, D_k$. Для кожної ітерації:

$$D_{train}^{(i)} = \bigcup_{j \neq i} D_j, \quad D_{val}^{(i)} = D_i.$$

Коректний процес вимагає, щоб усі трансформації навчалися заново на кожному $D_{train}^{(i)}$. Пайплайн забезпечує це автоматично, оскільки кожен виклик `fit` відбувається лише на тренувальній частині відповідного фолду. Без пайплайну така коректність практично недосяжна.

Пайплайни та підбір гіперпараметрів

При підборі гіперпараметрів ми мінімізуємо оцінку ризику:

$$\hat{R}(\lambda) = \frac{1}{k} \sum_{i=1}^k \mathcal{L}(f_{\theta(\lambda)}^{(i)}, D_{val}^{(i)}),$$

де λ — набір гіперпараметрів як моделі, так і трансформацій.

Пайплайн дозволяє розглядати параметри підготовки даних (наприклад, кількість компонент PCA або тип масштабування) як повноцінні гіперпараметри, що оптимізуються разом із параметрами моделі. Це принципово важливо, оскільки якість моделі в значній мірі залежить від підготовки даних, не тільки від вибору алгоритму.

Пайплайни як захист від витіку ознак

З теоретичної точки зору витік ознак означає, що ми оцінюємо ризик:

$$\hat{R}_{leak} = \mathbb{E}_{(x,y) \sim \mathcal{D}_{test}} [\mathcal{L}(f_{\theta^*}(T_{full}(x)), y)],$$

де T_{full} навчений на повному датасеті. Це дає оптимістичну, але хибну оцінку.

Пайплайн гарантує, що оцінюється коректний ризик:


$$\hat{R}_{true} = \mathbb{E}_{(x,y) \sim \mathcal{D}_{test}} [\mathcal{L}(f_{\theta^*}(T_{train}(x)), y)].$$

MLOps

MLOps (Machine Learning Operations) — це міждисциплінарний підхід, який поєднує машинне навчання, інженерію програмного забезпечення та операційну підтримку з метою створення, розгортання та супроводу ML-моделей у реальних системах. На концептуальному рівні MLOps є аналогом DevOps, адаптованим до специфіки машинного навчання.

Ключова відмінність ML-систем від традиційного програмного забезпечення полягає в тому, що їх поведінка визначається не лише кодом, а й даними. Якщо у класичному програмному забезпеченні функція $y = g(x)$ повністю задається кодом, то у машинному навчанні вона має вигляд $y = f_{\theta}(x)$, де параметри θ отримуються шляхом оптимізації на даних. Отже, будь-яка зміна у даних, способі їх підготовки або в умовах застосування моделі може суттєво змінити поведінку системи навіть без змін у коді.

MLOps



Основні задачі та проблеми, які вирішує MLOps

MLOps з'явився як відповідь на практичні труднощі, що виникають під час переходу від експериментальних моделей до промислового використання. Серед них — неможливість відтворити результати навчання, неконтрольований витік ознак, деградація якості моделі з часом, складність масштабування та відсутність прозорості рішень.

Формально, у MLOps ключовою є ідея контролю повного життєвого циклу моделі. Якщо позначити розподіли даних як $P_{train}(X, Y)$ та $P_{prod}(X, Y)$, то реальна система повинна бути здатною виявляти ситуації, коли

$$P_{train} \neq P_{prod},$$

і реагувати на це шляхом переналаштування або зупинки моделі. Без автоматизованих пайплайнів та моніторингу це завдання є складним.

Роль пайплайнів у MLOps

У MLOps пайплайн машинного навчання розглядається не просто як зручний інструмент, а як формальний опис процесу перетворення "сирих" даних у прогноз. Математично пайплайн описується як композиція операторів:

$$\mathcal{P} = f_{\theta} \circ T_{m-1} \circ \cdots \circ T_0,$$

де T_i — трансформації даних, а f_{θ} — модель.

У межах MLOps кожна така композиція є версіонованим артефактом. Це означає, що модель у продакшені ніколи не існує окремо від пайплайну підготовки даних.

Відтворюваність та контроль експериментів

Однією з фундаментальних вимог MLOps є відтворюваність. Для фіксованих даних, параметрів та версії пайплайну результат навчання має бути детермінованим. Це дозволяє пов'язати якість моделі з конкретними змінами в пайплайні, а не з випадковими флуктуаціями.

З формальної точки зору, це означає, що функція навчання

$$\theta^* = \arg \min_{\theta} \mathcal{L}(f_{\theta}(T(X)), y)$$

повинна бути стабільною відносно неістотних змін середовища виконання.

Безперервне навчання та контроль дрейфу

У робочому середовищі пайплайн стає основою для безперервного навчання. Коли нові дані надходять у систему, ті самі трансформації T застосовуються автоматично, що дозволяє коректно порівнювати нові спостереження з історичними.

Моніторинг статистик трансформованих ознак дозволяє виявляти data drift, тобто зміну розподілів або зв'язків між ознаками та ціллю. Це ключовий аспект MLOps, який складно реалізувати без чітко визначених пайплайнів.

Пайплайни та Explainable AI

Explainable AI працює не з моделлю f_θ як такою, а з композицією $f_\theta \circ T$. SHAP, наприклад, будує адитивне представлення:

$$f(T(x)) = \mathbb{E}[f(T(X))] + \sum_i \phi_i,$$

де ϕ_i — внески трансформованих ознак.

Без явного пайплайну ці внески втрачають семантичну інтерпретацію, оскільки не зрозуміло, як саме були отримані ознаки, які пояснюються.

Пайплайн як інструмент виявлення витoku ознак

Пояснюваність у поєднанні з пайплайнами дозволяє виявляти логічні та часові помилки в підготовці даних. Якщо, наприклад, SHAP-пояснення показують домінування ознак, що формуються після моменту прийняття рішення, це свідчить про темпоральний витік. Наявність пайплайну дозволяє точно локалізувати джерело цієї проблеми.